

# AI 알고리즘

## 비선형계획법


# 라그랑지 방법과 쿤-터커 조건법

라그랑지 방법

## 라그랑지 방법

### ❖ 일반적인 비선형계획문제의 해법

- 제약조건이 없는 경우 미분법을 통한 필요조건과 충분조건에 의해 극값을 판단
- 제약조건이 있는 경우 해영역의 정점들에서도 국소 최적해가 나올 수 있음



- 제약조건이 없는 것처럼 할 수 있을까?

### ❖ 제약 조건이 있는 경우의 최적해 도출방법

- 제약조건 등식인 경우 → 라그랑지 방법 사용
- 제약조건 부등식인 경우 → 쿤-터커 조건법 사용

### ❖ 라그랑지 방법(Lagrange Method)

- 미분이 가능하고 제약조건식에 부등호 대신 등호만을 가진 비선형계획문제는 라그랑지 승수를 이용하여 최적해를 찾을 수 있음
- 편미분 함수 활용한 최적해 도출은 명확한 정보가 없으므로 적용이 불가능함
- 이러한 경우에는 라그랑지 승수(Lagrange Multiplier)를 도입
  - 제약이 있는 비선형계획모형
  - 제약이 없는 비선형계획모형으로 변경

## 라그랑지 방법

### ❖ 라그랑지 방법(Lagrange Method)

$$\text{Maximize}(\text{Minimize}) Z = f(x_1, x_2, \dots, x_n)$$

$$\text{s. t.} \quad g_i(x_1, x_2, \dots, x_n) = b_i$$

$$x_j \geq 0, \quad i = 1, \dots, m, \quad j = 1, \dots, n$$

$\lambda_i \geq 0$ ,  
라그랑지 승수 도입

$$L(x_1, x_2, \dots, x_n, \lambda_1, \lambda_2, \dots, \lambda_m)$$

$$= f(x_1, x_2, \dots, x_n) + \sum_{i=1}^m \lambda_i [b_i - g_i(x_1, x_2, \dots, x_n)]$$

- 라그랑지 방법을 이용하여 제약식 제거
- 변경된 비선형 계획 모형의 최적해가 원 비선형 계획 모형의 최적해가 되기 위한 조건
  - $\frac{\partial L}{\partial x_j} = 0 \quad (j = 1, \dots, n), \quad \frac{\partial L}{\partial \lambda_i} = 0 \quad (i = 1, \dots, m)$
  - 즉,  $\frac{\partial L}{\partial x_j} = \frac{\partial f}{\partial x_j} - \sum_{i=1}^m \lambda_i \frac{\partial g_i}{\partial x_j} = 0, \quad \frac{\partial L}{\partial \lambda_i} = b_i - g_i(x_1, x_2, \dots, x_n) = 0$
- $f(x_1, x_2, \dots, x_n)$ 가 볼록함수이고,  $g_i(x_1, x_2, \dots, x_n)$ 가 선형함수
- $f(x_1, x_2, \dots, x_n)$ 가 오목함수이고,  $g_i(x_1, x_2, \dots, x_n)$ 가 선형함수

### ❖ 라그랑지 승수의 의미

- 다른 변수들이 일정할 때 제약 조건식의 우변 상수인  $b$ 가 변화함으로써 목적함수  $f$ 가 변화되는 양을 의미
- 새로운 알고리즘을 배울 때 상당히 유용할 수 있음
  - 결국  $\lambda$  는  $g(x)$ 에서의 변화에 따른  $f(x)$ 에서의 변화를 나타냄

$$L(x, \lambda) = f(x) + \lambda(b - g(x))$$

$$\frac{\partial L}{\partial x} = \frac{\partial f(x)}{\partial x} - \lambda \frac{\partial g(x)}{\partial x} = 0$$

$$\lambda = \frac{\partial f(x)}{\partial g(x)} = 0$$

## 라그랑지 방법

### ❖ 예제

- 함수 충분조건에 의해 최대, 최솟값을 구할 수 있음

등식인 제약식을 없애는 것

$$\text{Minimize } z(x) = x_1^2 + x_2^2 + x_3^2$$

$$\text{s.t. } x_1 + x_2 + x_3 = 6$$

$$L(x, \lambda)$$

$$= x_1^2 + x_2^2 + x_3^2 + \lambda(6 - x_1 - x_2 - x_3)$$

편미분을 활용하여  
자기 변수 외에 모두 상수로 취급

$$L(x, \lambda) = x_1^2 + x_2^2 + x_3^2 + \lambda(6 - x_1 - x_2 - x_3)$$

$$\frac{\partial L(x, \lambda)}{\partial x_1} = 2x_1 - \lambda = 0$$

$$\frac{\partial L(x, \lambda)}{\partial \lambda} = 6 - x_1 - x_2 - x_3 = 0$$

$$\frac{\partial L(x, \lambda)}{\partial x_2} = 2x_2 - \lambda = 0$$

$$\frac{\partial L(x, \lambda)}{\partial x_3} = 2x_3 - \lambda = 0$$

$$\lambda = 4$$

$$x_1 = x_2 = x_3 = 2$$

$$H = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

$$M_1 = 2, M_2 = 4, M_3 = 8$$

함수  $f(x_1, x_2, \dots, x_n)$  는 완전  
볼록함수이므로 최적해를 가짐

# 라그랑지 방법과 쿤-터커 조건법

쿤 - 터커 조건법

## 쿤-터커 조건법

### ❖ 쿤-터커 조건법 개념

- 비선형계획모형의 제약조건이 전부 또는 일부가 부등식이면 라그랑지 방법을 적용할 수 없음
- 라그랑지 방법을 확장하여 최적해를 구함
  - 이때 최적해를 얻기 위한 필요충분조건이 쿤-터커 조건
- 일반적인 비선형계획문제 고려

$$\begin{aligned}
 & \text{Maximize } Z = f(x_1, x_2, \dots, x_n) \\
 & \text{s.t.} \quad g_1(x_1, x_2, \dots, x_n) \leq b_1 \\
 & \quad \quad g_2(x_1, x_2, \dots, x_n) \leq b_2 \\
 & \quad \quad \vdots \\
 & \quad \quad g_m(x_1, x_2, \dots, x_n) \leq b_m
 \end{aligned}$$

- 제약식의 부등식을 등식으로 전환
  - 새로운 인위 변수를 좌변에 더해줌

$$s_i^2 = b_i - g_i(x_j)$$

$$\begin{aligned}
 & \text{Maximize } Z = f(x_1, x_2, \dots, x_n) \\
 & \text{s.t.} \quad g_1(x_1, x_2, \dots, x_n) - b_1 + s_1^2 = 0 \\
 & \quad \quad g_2(x_1, x_2, \dots, x_n) - b_2 + s_2^2 = 0 \\
 & \quad \quad \vdots \\
 & \quad \quad g_m(x_1, x_2, \dots, x_n) - b_m + s_m^2 = 0
 \end{aligned}$$

- 등식 제약조건으로 전환되었으므로 라그랑지 승수 도입

$$L(x_j, s_i, \lambda_i) = f(x_j) - \sum_{i=1}^m \lambda_i (g_i(x_j) - b_i + s_i^2)$$

## 쿤-터커조건법

### ❖ 쿤-터커 조건법 개념

- 극점이 되기 위한 필요조건

$$\begin{aligned}\frac{\partial L}{\partial x_j} &= \frac{\partial f}{\partial x_j} - \sum_{i=1}^m \lambda_i \frac{\partial g_i}{\partial x_j} = 0 \\ \frac{\partial L}{\partial \lambda_i} &= -(g_i(x_j) - b_i + s_i^2) = 0 \\ \frac{\partial L}{\partial s_i} &= -2\lambda_i s_i = 0\end{aligned}$$

- $\lambda_i$  또는  $s_i$  중 적어도 하나는 0
- $s_i = 0$  일때,  
 $g_i(x_j) - b_i = 0$  이므로  $\lambda_i(g_i(x_j) - b_i) = 0$
- 또한, 두 번째 제약 조건식을 표시한 것이므로  $g_i(x_j) - b_i < 0$  으로 나타낼 수 있음
- 따라서, 인위 변수 없이 조건을 표시할 수 있음

$$\begin{aligned}\frac{\partial L}{\partial x_j} &= \frac{\partial f}{\partial x_j} - \sum_{i=1}^m \lambda_i \frac{\partial g_i}{\partial x_j} = 0 \\ \frac{\partial L}{\partial \lambda_i} &= g_i(x_j) - b_i \leq 0 \\ \frac{\partial L}{\partial s_i} &= \lambda_i(g_i(x_j) - b_i) = 0\end{aligned}$$

- 필요조건은 만일  $f(x_1, x_2, \dots, x_n)$  가 오목하고,  $g_i(x_1, x_2, \dots, x_n)$  의 실행 가능 영역이 볼록하면 충분조건이 되기도 함
- 이것은 함수  $f(x_1, x_2, \dots, x_n)$  이 오목하고,  $g_i(x_1, x_2, \dots, x_n)$  이 볼록할 경우 라그랑지 함수  $L(x_j, s_i, \lambda_i)$  가 오목하기 때문
- $L(x_j, s_i, \lambda_i) = f(x_j) - \sum_{i=1}^m [\lambda_i(g_i(x_j) - b_i) + \lambda_i s_i^2]$  에서  $\lambda_i s_i^2 = 0$  이고,  
 $g_i(x_j) - b_i$  는 볼록하고  $\lambda_i \geq 0$  이므로  $\lambda_i(g_i(x_j) - b_i)$  도 볼록하고,  $-\lambda_i(g_i(x_j) - b_i)$  는 오목
- 따라서,  $f(x_j) - \sum_{i=1}^m [\lambda_i(g_i(x_j) - b_i) + \lambda_i s_i^2]$  도 오목



## 쿤-터커조건법

### ❖ 예제

$$\begin{aligned} & \text{Max } x_1 x_2 \\ & \text{s. t.} \\ & \quad 2x_1 + x_2 \leq 16 \\ & \quad x_1, x_2 \geq 0 \end{aligned}$$

#### ■ 라그랑지함수

$$\begin{aligned} L(x, s, \lambda) = & x_1 x_2 - \lambda_1 (2x_1 + x_2 - 16 + s_1^2) \\ & - \lambda_2 (-x_1 + s_2^2) - \lambda_3 (-x_2 + s_3^2) \end{aligned}$$

$$L(x, s, \lambda) = x_1 x_2 - \lambda_1 (2x_1 + x_2 - 16 + s_1^2) - \lambda_2 (-x_1 + s_2^2) - \lambda_3 (-x_2 + s_3^2)$$

$$\begin{aligned} \frac{\partial L}{\partial x_1} = x_2 - 2\lambda_1 + \lambda_2 &= 0 & \lambda_1 (2x_1 + x_2 - 16) &= 0 \\ \frac{\partial L}{\partial x_2} = x_1 - \lambda_1 + \lambda_3 &= 0 & \lambda_2 x_1 &= 0 \\ & & \lambda_3 x_2 &= 0 \\ 2x_1 + x_2 &\leq 16 & \lambda_1, \lambda_2, \lambda_3 &\geq 0 \\ x_1, x_2 &\geq 0 \end{aligned}$$

- $\lambda_2 \neq 0, \lambda_3 \neq 0$ 인 경우
  - 물리적모형
  - $\lambda_2 x_1 = 0$ 에 의해  $x_1 = 0$ ,  $\lambda_3 x_2 = 0$ 에 의해  $x_2 = 0$
  - $\lambda_1 (2x_1 + x_2 - 16) = 0$ 에 의해  $\lambda_1 = 0$
  - 이를  $\frac{\partial L}{\partial x_1}$  과  $\frac{\partial L}{\partial x_2}$  에 대입하면,  $\lambda_2 = 0, \lambda_3 = 0$
  - 조건을 만족시키지 못함

$$\begin{aligned} \frac{\partial L}{\partial x_1} = x_2 - 2\lambda_1 + \lambda_2 &= 0 \\ \frac{\partial L}{\partial x_2} = x_1 - \lambda_1 + \lambda_3 &= 0 \end{aligned}$$

## 쿤-터커 조건법

### ❖ 예제

- $\lambda_2 \neq 0, x_2 \neq 0$ 인 경우
  - $\lambda_2 x_1 = 0$ 에 의해  $x_1 = 0, \lambda_3 x_2 = 0$ 에 의해  $\lambda_3 = 0$
  - 이를  $\frac{\partial L}{\partial x_1}$ 과  $\frac{\partial L}{\partial x_2}$ 에 대입하면,  $x_2 + \lambda_2 = 0, \lambda_1 = 0$
  - $x_2 = -\lambda_2$  둘다 양수에 위배
  - 조건을 만족시키지 못함

$$\begin{aligned}\frac{\partial L}{\partial x_1} &= x_2 - 2\lambda_1 + \lambda_2 = 0 \\ \frac{\partial L}{\partial x_2} &= x_1 - \lambda_1 + \lambda_3 = 0\end{aligned}$$



- $x_1 \neq 0, \lambda_3 \neq 0$ 인 경우
  - $\lambda_2 x_1 = 0$ 에 의해  $\lambda_2 = 0, \lambda_3 x_2 = 0$ 에 의해  $x_2 = 0$
  - 이를  $\frac{\partial L}{\partial x_1}$ 과  $\frac{\partial L}{\partial x_2}$ 에 대입하면,  $\lambda_1 = 0, x_1 + \lambda_3 = 0$
  - $x_1 = -\lambda_3$  둘다 양수에 위배
  - 조건을 만족시키지 못함

$$\begin{aligned}\frac{\partial L}{\partial x_1} &= x_2 - 2\lambda_1 + \lambda_2 = 0 \\ \frac{\partial L}{\partial x_2} &= x_1 - \lambda_1 + \lambda_3 = 0\end{aligned}$$

## 쿤-터커 조건법

### ❖ 예제

- $x_1 \neq 0, x_2 \neq 0$ 인 경우
  - $\lambda_2 x_1 = 0$ 에 의해  $\lambda_2 = 0, \lambda_3 x_2 = 0$ 에 의해  $\lambda_3 = 0$
  - 이를  $\frac{\partial L}{\partial x_1}$ 과  $\frac{\partial L}{\partial x_2}$ 에 대입하면,  $x_2 - 2\lambda_1 = 0, x_1 - \lambda_1 = 0$
  - $\lambda_1 = 0, 2x_1 + x_2 - 16 \neq 0$  이면
    - $x_1 = \lambda_1 = 0, x_2 = 2\lambda_1 = 0$ , 위배
  - $\lambda_1 \neq 0, 2x_1 + x_2 - 16 = 0$ 이면
    - $x_1 = \lambda_1, x_2 = 2\lambda_1, 2\lambda_1 + 2\lambda_1 - 16 = 0$
    - 따라서,  $\lambda_1 = 4, x_1 = 4, x_2 = 8, Z = 32$
- $\lambda_1 = 4, x_1 = 4, x_2 = 8, Z = 32$



## 쿤-터커 조건법

### ❖ 쿤-터커 정리(Kuhn-Tucker Theorem)

$$\begin{aligned} & \text{Minimize } z(x_1, x_2, \dots, x_n) \\ & \text{subject to } h_j(x_1, x_2, \dots, x_n) = 0, \forall j \in \{1, 2, \dots, m\} \\ & \quad g_k(x_1, x_2, \dots, x_n) \leq 0, k \in \{1, 2, \dots, r\} \end{aligned}$$

$\lambda_j, \mu_k$   
라그랑지 승수 도입

$$L(x, \lambda, \mu) = z(x) + \sum_{j=1}^m \lambda_j h_j(x) + \sum_{k=1}^r \mu_k g_k(x)$$

$$A(x) = \{k | g_k(x) = 0\} \text{ 활성부등식}$$

- 주어진 비선형 계획 모형에 대해 국소 최솟값  $(x^*, \lambda^*, \mu^*)$  이 존재한다면

$$\begin{aligned} \nabla L(x^*, \lambda^*, \mu^*) &= 0 \\ \mu_k^* &\geq 0, \forall k \in \{1, 2, \dots, r\} \\ \mu_j^* &= 0, \forall j \notin A(x) \end{aligned}$$

### ❖ 2차 계획기법(Quadratic Programming)

- 목적함수 중 2차 함수 부분이 오목(최대화)하거나 볼록(최소화)하고 제약 조건이 모두 1차인 경우에 적용되는 해법
- 비선형 계획법의 쿤-터커 조건을 선형 계획법으로 해결하는 기법

### ❖ 분리볼록 계획기법(Separable Convex Programming)

- 목적함수나 제약 조건이 변수에 따라 분리될 수 있는 함수
- 목적함수가 최대화의 경우 오목하고 제약 조건이 볼록한 경우에 적용되는 해법

### ❖ 기하 계획기법(Geometric Programming)

- 목적함수의 지수가 음이 될 수 있는 고차다항식으로 되어 있을 때 적용될 수 있는 해법