

# AI 알고리즘

발견적 해법

# 발견적 해법의 개념

다양한 발견적 해법

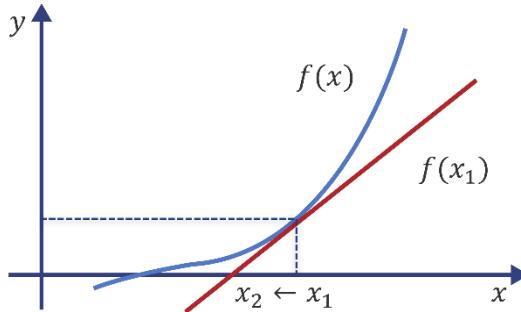
## 다양한 발견적 해법

### ❖ 발견적 해법(Heuristic Method)

- 문제 자체의 복잡성 때문에 최적해를 구하는 의사결정 기법의 개발이 매우 어려움
- 최적해는 아니더라도 상대적으로 짧은 시간 내에 적절한 수준의 의사결정을 내릴 수 있는 기법

### ❖ 뉴턴법(Newton's Method)

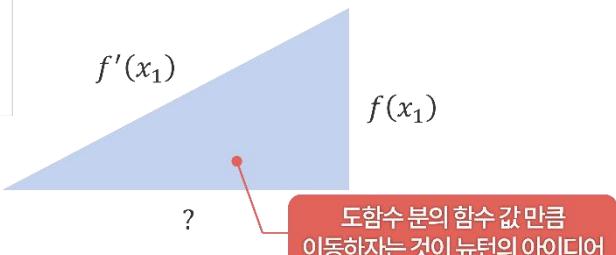
- 방정식  $f(x)=0$ 의 해를 근사적으로 찾을 때 유용하게 사용되는 방법
  - 임의의 값  $x=a$ 를 넣고  $f(a)$ 의 값을 구함
  - 만일  $f(a)>0$ 이고  $f'(a)>0$ 라면  $f(x)=0$ 이 되는  $x$ 는  $a$ 보다 작은 값일 것
- 얼마나 값을 줄여야 하는가?
- 기울기를 구해보는 것
  - 미분값이 양수일 때 작은 쪽으로 움직임
- 현재  $x$  값에서 접선을 그리고 접선이  $x$  축과 만나는 지점으로  $x$ 를 이동시켜 가면서 점진적으로 해를 찾는 방법



- 알고리즘
  - 아무 값이나 초기 값  $x_1$ 에서 시작
  - 다음 수식에 따라 수렴할 때까지 계속  $x$ 를 이동

$$x^{t+1} = x^t - \frac{f(x^t)}{f'(x^t)}$$

- 종료
  - $x$  값 변화가 거의 없을 때
  - 즉  $|x^{t+1} - x^t|$  가 매우 작은 값이면 종료



## 다양한 발견적 해법

### ❖ 뉴턴법(Newton's Method)

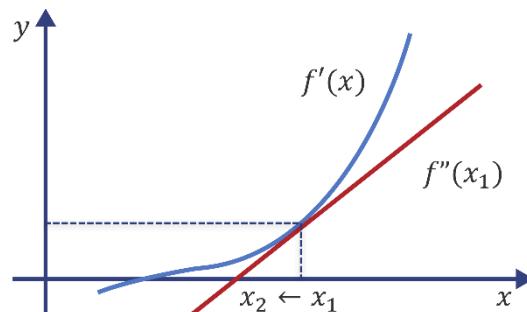
- 특징

- 해가 있더라도 뉴턴법으로 해를 못 찾을 수 있음
- $f(x)$ 가 연속이고 미분 가능해야 한다는 조건도 필요
- 만일  $f(x)=0$ 인 해가 여러 개 있다면 뉴턴법은 그 중 하나의 해를 찾아줄 뿐
- 또한 해가 여러 개인 경우에는 초기값  $x_1$ 을 어떻게 주느냐에 따라서 뉴턴법으로 찾아지는 해가 달라질 수 있음
- 초기값 선택
  - 초기값을 잘못 주면 시간이 오래 걸리거나 해를 찾지 못할 수도 있음
  - 먼저 일정한 간격으로  $x$  값을 변화시키면서 함수값의 변화를 본 후 함수값의 부호가 바뀌는 구간마다 보간법(Interpolation)으로 초기값을 잡는 것

- 활용

- $f(x)$ 의 최솟값 또는 최댓값을 구할 때 활용
  - 가장 좋은 후보군이 될 수 있는 극값
  - 기울기가 0인 점들을 찾을 때 활용 가능
  - 일반적으로 함수는 극점에서 최댓값 또는 최솟값을 가짐
  - $f'(x)=0$ 인  $x$ 를 뉴턴법으로 구한 후  $f(x)$ 에 대입하면  $f(x)$ 의 최댓값, 최솟값을 구할 수 있음

$$x^{n+1} = x^n - \frac{f'(x)}{f''(x)}$$



## 다양한 발견적 해법

### ❖ 테일러 급수 또는 테일러 전개

- 어떤 미지의 함수  $f(x)$ 를 근사 다항함수로 표현하는 것

$$f(x) \cong f(a) + f'(a)(x - a) + \frac{f''(a)}{2}(x - a)^2 + \cdots + \frac{f^n(a)}{n!}(x - a)^n$$

- $x=a$  근처에서만 성립,  $x$ 가  $a$ 에서 멀어지면 오차가 커짐
- 잘 모르거나 복잡한 함수를 다루기 쉽고 이해하기 쉬운 다항함수로 대체시키기 위함
- 테일러 정리(Taylor's Theorem)
  - $n$  번 미분 가능한 함수  $f(x)$ 에 대해, 다음을 만족하는 실함수  $h(x)$ 가 반드시 존재

$$f(x) = f(a) + f'(a)(x - a) + \cdots + \frac{f^n(a)}{n!}(x - a)^n + h_n(x)(x - a)^n$$

$$\lim_{x \rightarrow a} h_n(x) = 0$$

- 테일러 정리(Taylor's Theorem)는 어떤 함수를 유한 차수( $n$  차)의 다항함수로 근사 시킬 수 있는 수학적 근거를 제공

### ❖ 최소자승법(Least Square Method)

- 어떤 모델의 파라미터를 구하는 한 방법으로서 데이터와의  $residual^2$ 의 합을 최소화하도록 모델의 파라미터를 구하는 방법
- 추측의 에러를 적게 하는 것
- $\sum_{i=1}^n r_i^2 = \sum_{i=1}^n (y_i - f(x_i))^2$  를 최소화
- $F(x)$  가 직선  $ax+b$  인 경우,  $\sum_{i=1}^n (y_i - ax_i - b)^2$  를 최소화하는  $a, b$  결정
- 어떤 기준을 가지고 모델의 파라미터를 구하는가를 말해줄 뿐 실제로 어떻게 계산하는가는 별개의 문제
  - 대수적 방법
    - 행렬식 형태로 표현한 후에 선형 대수학을 적용하는 방법
  - 해석학적 방법
    - 식을 각각의 모델 파라미터들로 편미분한 후에 그 결과를 0 으로 놓고 연립 방정식을 푸는 것

## 다양한 발견적 해법

### ❖ Gradient Descent 방법(Steepest Descent 방법)

- 미분의 개념을 최적화 문제에 적용한 대표적 방법 중 하나
- 함수의 Local Minimum(Maximum)을 찾는 방법 중 하나
- Gradient Ascent 방법
  - 어떤 함수의 극대점을 찾기 위해 현재 위치에서의 Gradient 방향으로 이동해 가는 방법
- Gradient Descent 방법
  - 극소점을 찾기 위해 Gradient 반대 방향으로 이동해 가는 방법

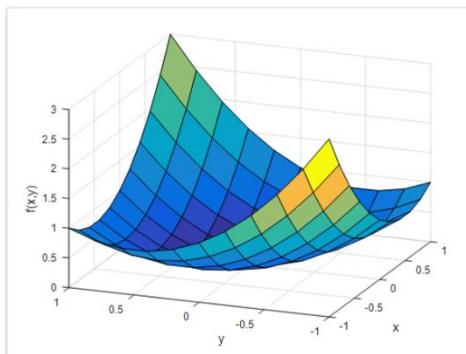
### ❖ 그레디언트(Gradient)

- 다변수 함수  $f(x_1, x_2, \dots, x_n)$ 이 있을 때  $f$ 의 그레디언트(Gradient)

$$\nabla f = \left( \frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

- 각 변수로의 일차 편미분 값으로 구성되는 벡터
- $f(x, y) = x^2 + xy + y^2$ 
  - $f$ 의 그레디언트(Gradient)
  - $(1, 1)$ 에서  $f$  값이 최대로 증가하는 방향은  $(3, 3)$ , 기울기는  $\| (3, 3) \| = \sqrt{18}$

$$\nabla f = \left( \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) = (2x + y, 2y + x)$$



## 다양한 발견적 해법

### ❖ Gradient Descent 방법(Steepest Descent 방법)

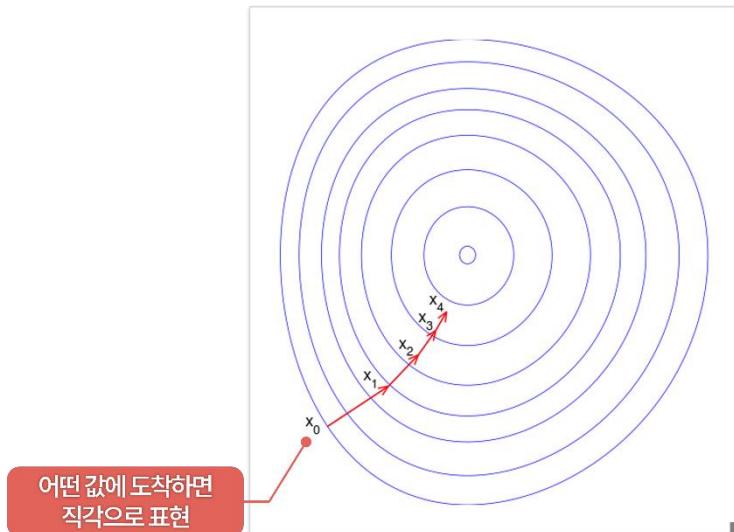
- 그레이디언트의 특성을 이용하여 어떤 비용함수의 값을 최소화시키기 위한 파라미터 값을 아래와 같이 점진적으로 찾는 방법

$$x_{k+1} = x_k - \lambda_k \nabla f(x_k), \quad k \geq 0$$

- マイ너스를 붙이고, 편미분 방향으로 작게 이동
- 즉, 어떤 초기값  $x_0$ 부터 시작하여 위 식에 따라 Gradient 반대 방향으로  $x$ 를 조금씩 이동시키면  $f(x)$ 가 극소가 되는  $x$ 를 찾을 수 있다는 방법

### ❖ 그레디언트(Gradient)

- $\lambda_k$ 는 알고리즘의 수렴 속도를 조절하는 파라미터로서 Step Size 또는 Learning Rate



## 다양한 발견적 해법

### ❖ Gradient Descent 방법(Steepest Descent 방법)

- 문제점
  - Local Minimum에 빠지는 것
  - 해에 근접할수록  $|\nabla f|$  가 0에 가까워지기 때문에 수렴 속도가 느려진다는 것
  - $\lambda$ 의 크기를 키움 → 수렴 속도에 문제
  - 알고리즘이 발산할 수 있는 문제점이 있음
- Gradient Descent 방법
- 뉴턴법(Newton's Method)
- 가우스-뉴턴법