

AI 알고리즘

마이코프 분석

마아코프 분석 사례

Hidden 마아코프 모델

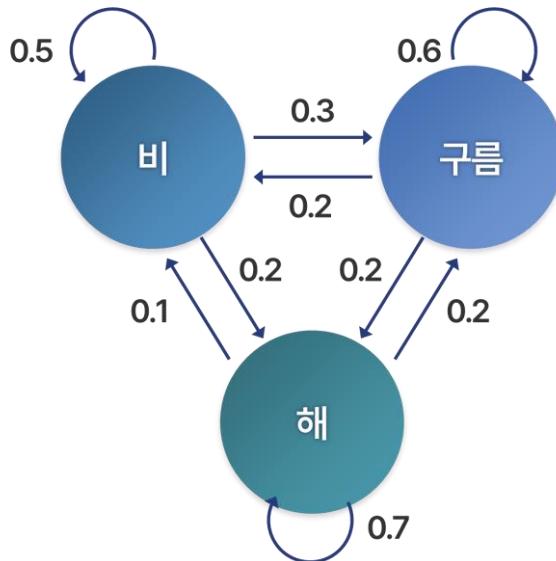
Hidden 마야코프 모델

❖ 마야코브 체인(Markov Chain)

- State: 날씨
 - Observable State(관측가능한 상태): 비, 구름, 해
 - 가정: 오늘날씨(Current State)는 어제날씨 (Previous State)에만 영향을 받음

$$\begin{aligned} P(x_{t+1} = j_{t+1} | x_t = j_t, x_{t-1} = j_{t-1}, \dots, x_1 = j_1, x_0 = j_0) \\ = P(x_{t+1} = j_{t+1} | x_t = j_t) \end{aligned}$$

$$P = \begin{matrix} & \text{비} & \text{구름} & \text{해} \\ \text{비} & \left[\begin{matrix} 0.5 & 0.3 & 0.2 \end{matrix} \right] \\ \text{구름} & \left[\begin{matrix} 0.2 & 0.6 & 0.2 \end{matrix} \right] \\ \text{해} & \left[\begin{matrix} 0.1 & 0.2 & 0.7 \end{matrix} \right] \end{matrix}$$



- 오늘 비 내리고 내일 비 올 확률이 0.5
- 오늘 비 내리고 내일 구름이 낄 확률이 0.3
- 오늘 비 내리고 내일 해가 뜰 확률이 0.2

Hidden 마야코프 모델

❖ 마야코브 체인(Markov chain)

- 날씨 예제
 - 과거의 관측지가 해 → 구름 → 비 → 해일 때 내일 날씨는?
 - 오늘 날씨가 해인 경우, 이전 3일간의 날씨 변화가 해 → 구름 → 구름일 확률은?

$$P(\text{해, 구름, 구름}) = P(\text{해})P(\text{구름} | \text{해})P(\text{구름} | \text{구름})$$

- 조건부 확률 형태로 표현할 수 있음
- 언어 모델

$$\checkmark P(\text{나는 오늘 축구화를 구매했다})$$

$$= P(\text{나는})x$$

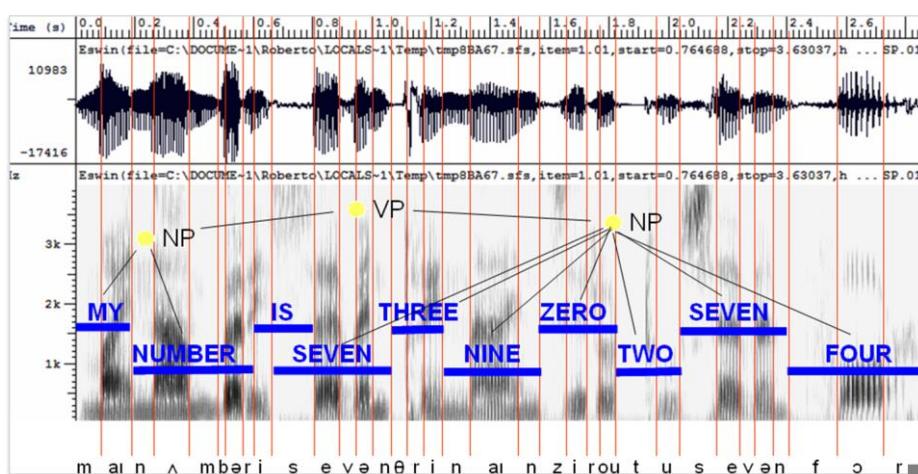
$$P(\text{오늘} | \text{나는})x$$
n-gram

$$P(\text{축구화를} | \text{오늘})x$$
bi-gram

$$P(\text{구매했다} | \text{축구화를})$$

❖ 은닉 마야코프 모델(Hidden Markov Model)

- 음향 모델
 - 파형으로 음소(한 언어의 음성체계에서 단어의 의미를 구별 짓는 최소의 소리 단위) 학습

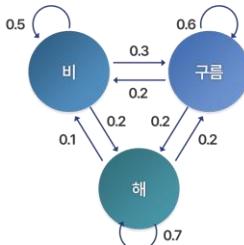


- 드러난 정보로 감춰진 정보를 알아낼 수 있는 방법

Hidden 마야코프 모델

❖ 은닉 마야코프 모델(Hidden Markov Model)

- State가 숨겨진 상태
 - 추정하고자 하는 State \neq 관측 데이터
 - State는 알 수 없고 관측 결과만 알 수 있는 경우
 - 날씨별 술의 판매량과의 연관성이 있다면 날씨 추측 가능
 - 관측 불가능한 은닉 상태를 관측이 가능한 결과를 통해 모델링
 - 우산 판매량 \rightarrow 날씨 추측 가능
 - 모델링하는 시스템이 미지의 모수를 가진 Markov Process로 가정
 - 가정에 기초해서 관측된 모수로부터 숨겨진 모수를 결정하려는 하나의 통계모델
- 순차 데이터, 문맥 의존 데이터를 인식하는 대표적 모델
 - 음성인식
 - 자연어처리
 - 생물정보학, DNA 분석 영역 속 활용



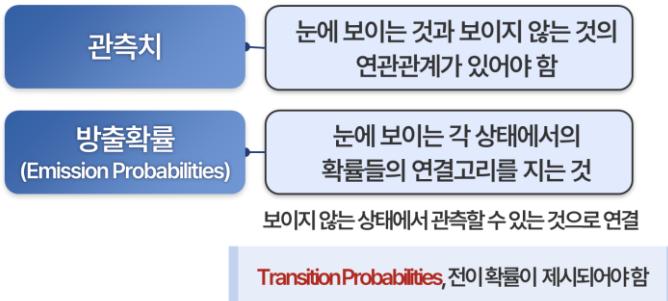
Hidden state

$$A = \begin{bmatrix} 0.5 & 0.3 & 0.2 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.2 & 0.7 \end{bmatrix}$$

Observations

$$B = \begin{bmatrix} 0.4 & 0.6 \\ 0.6 & 0.4 \\ 0.8 & 0.2 \end{bmatrix}$$

- 마이코프 모델의 표현 예시
- 마크 체인의 차이점



Hidden 마야코프 모델

❖ 은닉 마야코프 모델(Hidden Markov Model)

- 순차 데이터, 문맥 의존 데이터를 인식하는 대표적 모델
 - A: 상태전이확률
 - B: 각 상태에서 방출확률(Emission Probabilities)
 - π : 초기확률분포
 - $\lambda=(A, B, \pi)$
- 3가지 문제
 - ① 확률평가(Probability Evaluation) 문제
 - Forward, Backward 알고리즘
 - 관측값 다수 시 최적 모델 탐색
 - ② 최적의 상태(Optimal State Sequence)를 찾는 문제
 - Viterbi 알고리즘
 - 가장 최적의 은닉 상태 탐색
 - ③ 파라미터 추정(Parameter Estimation)의 문제
 - EM Baum-Welch 알고리즘
 - 은닉 상태 모델에서 최적해 탐색



최적의 모델을 탐색하는 확률평가문제 3개